

Diego Alonso Araujo Villegas

Estadística | UNMSM | Décimo Superior |

Portafolio: diegoarz02.github.io

LinkedIn: [diegoaraujo-data](https://www.linkedin.com/in/diegoaraujo-data)

Teléfono: +51 955 101 937

Email: diegoalonso.araujo24@gmail.com

PERFIL PROFESIONAL

Estudiante de Estadística en la UNMSM con experiencia en analítica avanzada, Machine Learning e IA aplicada al sector financiero. He trabajado en soluciones de NLP, Computer Vision, Deep Learning e IA Generativa dentro del área de Advanced Analytics del banco más grande del Perú, conectando problemas de negocio con soluciones analíticas que llegan a producción. Actualmente becario del programa de Data Science del Matsuo-Iwasawa Lab en la University of Tokyo y egresado del Samsung Innovation Campus en Big Data & AI. Destaco por mi capacidad para entender el problema detrás de los datos, diseñar la solución técnica adecuada y comunicar resultados a equipos no técnicos.

EXPERIENCIA LABORAL

Practicante CoE Advanced Analytics

Abr 2026 - Actualidad

Banco de Crédito del Perú (BCP)

Lima, Perú

- Traduzco necesidades de negocio en soluciones analíticas, conectando equipos funcionales con las capacidades de IA y Advanced Analytics del COE.
- Participo en el diseño y desarrollo de soluciones basadas en Machine Learning, NLP e IA Generativa para optimizar procesos internos del banco.
- Coordino la estructuración de activos de datos y la definición de requerimientos técnicos para proyectos del área.

Trainee Advanced Analytics e Inteligencia Artificial

Lima, Perú

Banco de Crédito del Perú (BCP)

Ene 2026 - Abr 2026

- Implementé una solución de IA Generativa (Azure OpenAI + IA Cognitiva) para auditar contratos mayoristas, reduciendo las alertas de falsos positivos en un 79% y llevando la exactitud de extracción de datos de 76% a 95%.
- Desarrollé soluciones de OCR avanzado con Computer Vision y detección de firmas, mejorando la precisión de extracción del 40% al 91%.
- Construí pipelines de preparación y procesamiento de datos para modelos predictivos, aplicando ML, Deep Learning y NLP en procesos de auditoría digital.

Practicante Business Analytics

Lima, Perú

Prestamype

Mar 2025 – Oct 2025

- Diseñé dashboards en Power BI para monitorear KPIs de cartera crediticia e indicadores de inversión, reemplazando reportes en Excel y mejorando la visibilidad para decisiones del equipo comercial.
- Implementé procesos ETL con Python para integrar datos de diversas fuentes y automaticé reportes financieros, reduciendo tiempos de generación de varias horas a menos de 5 minutos.
- Identifiqué patrones de comportamiento crediticio mediante análisis exploratorio que apoyaron la optimización de la estrategia de cobranza.

EDUCACIÓN

Estadística, Universidad Nacional Mayor de San Marcos

Mar 2022 - Actualidad

- Logros: Becario PRONABEC por Excelencia Académica, Décimo Superior.

Data Science Program (GCI World 2026),

Matsuo-Iwasawa Lab | University of Tokyo

Abr 2026-Actualidad

- Programa internacional intensivo de Data Science y ML.

Big Data & Artificial Intelligence, Samsung Innovation Campus

May2025 - Nov2025

- Formación en Big Data, Machine Learning y análisis de datos aplicados a inteligencia artificial.

CERTIFICACIONES

Advanced Machine Learning con TensorFlow y Keras, DMC

Abr 2026 – May 2026

Machine Learning, Datux

Mar 2026 – Abr 2026

Ciencia de Datos e IA Generativa, SmartData

Nov 2025 – Feb 2026

Generative AI Fundamentals, Databricks Academy

Ene 2026

Databricks Fundamentals, Databricks Academy

Ene 2026

Visualización de Datos en Power BI, Datux

Ene2024

SQL Server, CEDHINFO

Feb2024

HABILIDADES

Lenguajes y Herramientas: Python, R, SQL, PySpark, Power BI, Azure Machine Learning.

IA y Datos: Azure OpenAI, RAG, MCP, Agentes de IA, IA Generativa, LLMs. Pipelines ETL.

Machine Learning y AI: Scikit-learn, TensorFlow, Keras, PyTorch, XGBoost, Deep Learning, NLP, Computer Vision, MLflow, SHAP.

Herramientas y Cloud: Azure, AWS, Git, Docker.

Habilidades Blandas: Pensamiento analítico, resolución de problemas complejos, comunicación asertiva, adaptabilidad y orientación a resultados, trabajo en equipo, Metodologías Ágiles (Scrum).

PROYECTOS

Sistema MLOps de Predicción de Calidad en Flotación de Mineral — Sílice ([Git](#) · [Demo](#)):

- Desarrollé un sistema end-to-end de Data Science y MLOps que predice, una hora antes del laboratorio, el % de sílice del concentrado, con validación temporal sin fuga de datos y trazabilidad de experimentos en MLflow. El modelo seleccionado (LightGBM sobre el delta del target) supera al baseline de persistencia en MAE y R^2 en validación y test.
- Integré explicabilidad con SHAP, simulación what-if sobre palancas operativas y un agente de razonamiento (LangGraph + LLM) que redacta informes solo a partir de cifras verificadas. Lo desplegué como un único servicio FastAPI con interfaz web en Render.

Inteligencia de Fricción en E-Commerce: NLP e Inferencia Causal sobre reseñas de Olist ([Git](#)):

- Analicé ~100 000 reseñas reales en portugués del marketplace brasileño Olist combinando NLP y aspect-based sentiment analysis (ABSA) validado con BERT multilingüe (Transformers), sobre un pipeline de datos eficiente con Polars.
- Cuantifiqué las causas de la insatisfacción mediante inferencia causal (DoWhy), identificando el retraso en la entrega como el predictor causal más fuerte de una reseña negativa ($OR \approx 2.5-3.5$), y construí un motor preventivo de riesgo con reglas de asociación y grafos vendedor-categoría.

Detección de Melanoma con Transfer Learning e Inception-v3 ([Git](#)):

- Construí un clasificador de imágenes dermatoscópicas (benigno vs. maligno) mediante transfer learning sobre Inception-v3 con entrenamiento bifásico (extracción de características + fine-tuning), alcanzando AUC-ROC de 0.896 sobre un conjunto de prueba independiente.

Hub Interactivo de Deep Learning: comparación MLP vs CNN vs RNN ([Git](#) · [Demo](#)):

- Desarrollé un ecosistema interactivo en Python (TensorFlow, FastAPI) para comparar arquitecturas de Deep Learning sobre Fashion-MNIST, con inferencia en tiempo real mediante un lienzo web.
- Visualicé métricas avanzadas (matrices de confusión y heatmaps de activación) para interpretar cómo cada red abstrae características.

IDIOMAS

Español: Nativo

Ingles: Intermedio - B2 (en progreso)