Análisis Exploratorio del PBI Mensual de Perú (2007–2025)

Resumen

Este trabajo presenta un análisis exploratorio de la serie temporal mensual del Producto Bruto Interno (PBI) de Perú en el periodo 2007–2025. Se busca identificar patrones de tendencia, estacionalidad y variaciones cíclicas a través de herramientas gráficas y métodos de descomposición de series temporales. Asimismo, se incluyen medidas descriptivas, visualizaciones con boxplots y la detección de posibles valores atípicos. El objetivo es ilustrar los pasos iniciales de un análisis de series temporales en R, sirviendo como base para aplicaciones posteriores de modelos predictivos más avanzados.

1. Introducción

El análisis de series temporales constituye una herramienta fundamental para el estudio de variables económicas, dado que permite reconocer dinámicas subyacentes y comportamientos recurrentes en el tiempo. En particular, el Producto Bruto Interno (PBI) es uno de los indicadores más relevantes para evaluar el desempeño de la economía de un país. En este documento se explora la serie mensual del PBI de Perú correspondiente al periodo 2007–2025, con el propósito de identificar tendencias generales, estacionalidad y eventos atípicos.
El estudio se centra en la fase exploratoria, sin aplicar aún modelos predictivos como ARIMA o SARIMA, pero estableciendo las bases necesarias para futuros trabajos en pronósticos y modelamiento económico.

2. Datos y Herramientas

El análisis se realizó en el lenguaje de programación **R**, empleando librerías diseñadas para el tratamiento de series temporales y visualización de datos. Entre ellas destacan: `seasonal`, `tsibble`, `feasts`, `forecast`, `zoo`, `lubridate` y `ggplot2`. Estas herramientas permiten realizar descomposiciones, análisis de autocorrelación, gráficos exploratorios y detección de valores atípicos.
La base de datos utilizada corresponde a un archivo en formato Excel que contiene el Producto Bruto Interno mensual (PBI) de Perú para el periodo 2007–2025. Los datos fueron transformados en una serie temporal con frecuencia mensual mediante el siguiente código en R:

Cargar datos en R

```
library(readxl)
data2 <- read_excel("PBI.xlsx")
PBI <- ts(data2$PBIM, start = 2007, frequency = 12)
```

3. Visualización de la serie

Con el objetivo de conocer el comportamiento del Producto Bruto Interno (PBI) mensual del Perú, se realizan distintas representaciones gráficas. Estas permiten explorar patrones de tendencia, estacionalidad y posibles valores atípicos en la serie temporal. La visualización es una etapa esencial en el análisis de series de tiempo, ya que brinda una primera aproximación a la dinámica de los datos.

3.1. Serie temporal original

En la Figura 1 se observa la evolución mensual del PBI en el periodo 2007–2025. La tendencia general es creciente, lo cual refleja el crecimiento económico en el tiempo. Sin embargo, se aprecia un fuerte descenso en el año 2020, correspondiente al impacto económico de la pandemia de COVID-19, seguido de una recuperación gradual. Asimismo, los picos y valles recurrentes muestran un marcado componente estacional.

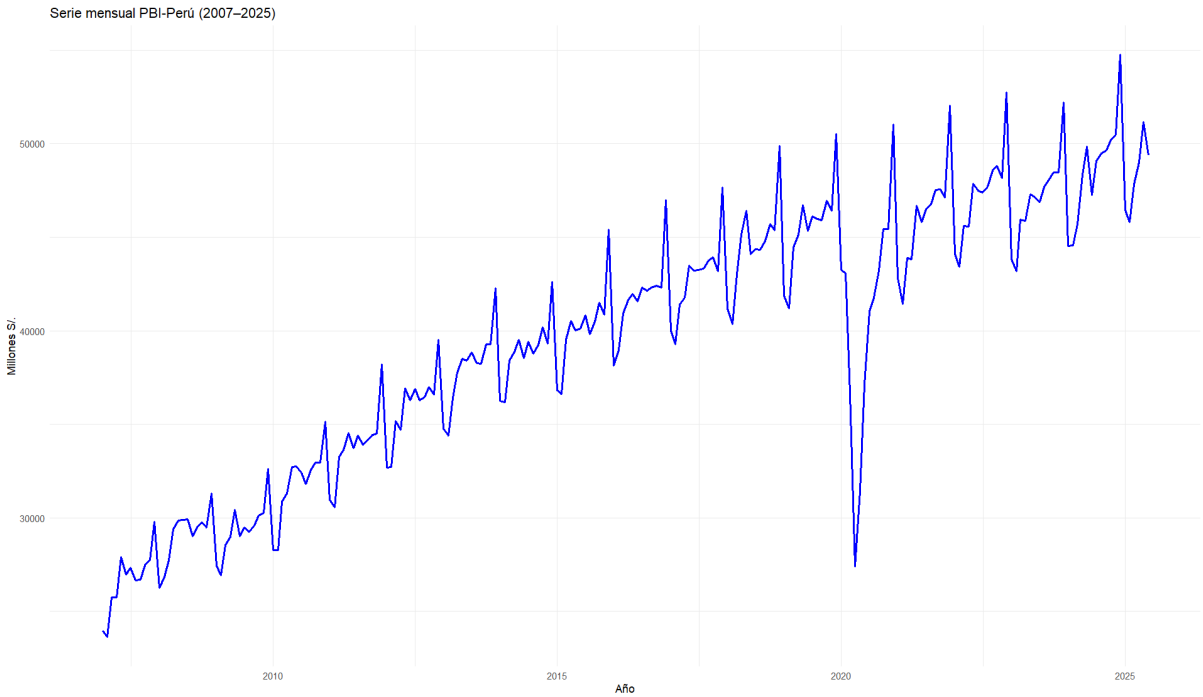

Figura 1: Serie mensual del PBI de Perú (2007–2025).

3.2. Comportamiento mensual

La Figura 2 presenta un *boxplot* del PBI por cada mes del año. Se observa que los valores tienden a aumentar en los últimos meses, destacando diciembre como el mes de mayor concentración de valores altos, mientras que los primeros meses del año concentran valores relativamente más bajos.Esto evidencia un patrón estacional ligado al ciclo económico anual.

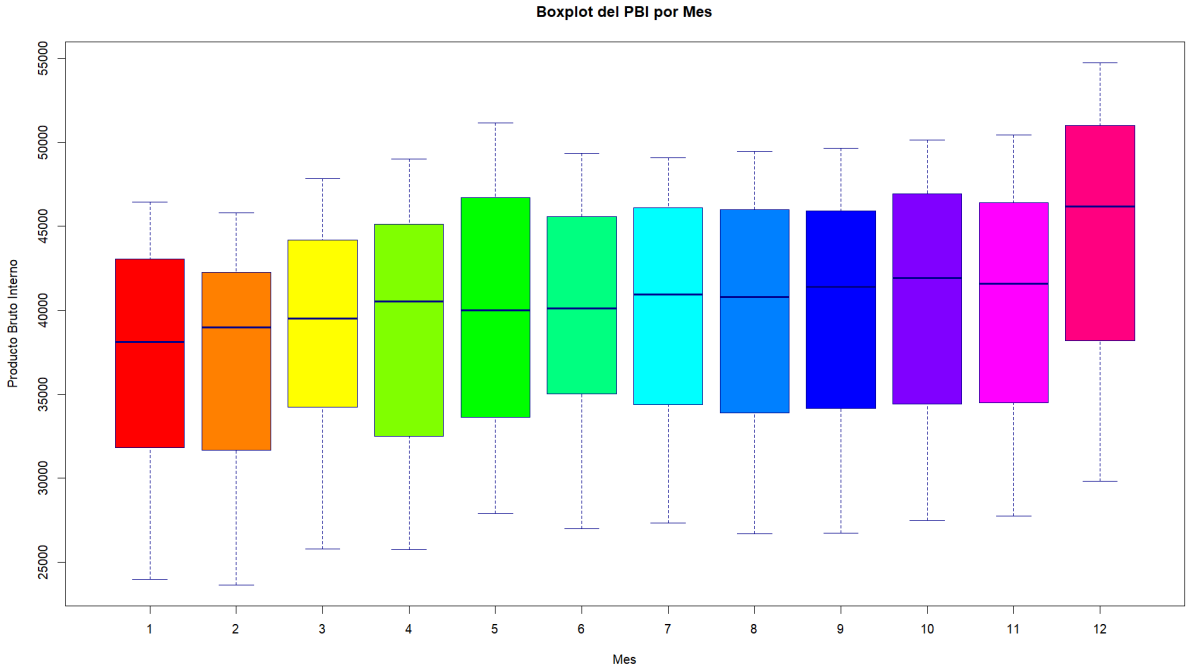

Figura 2: Boxplot del PBI mensual (2007–2025).

3.3. Distribución anual

En la Figura 3 se muestra un gráfico de cajas agrupado por año. Este permite visualizar la dispersión y tendencia de la serie anualizada. Se aprecia un crecimiento sostenido desde 2007 hasta 2019, seguido por una abrupta caída en 2020 (efecto pandemia). Posteriormente, el PBI retoma su crecimiento, aunque con cierta variabilidad, lo cual refleja un proceso de recuperación económica.

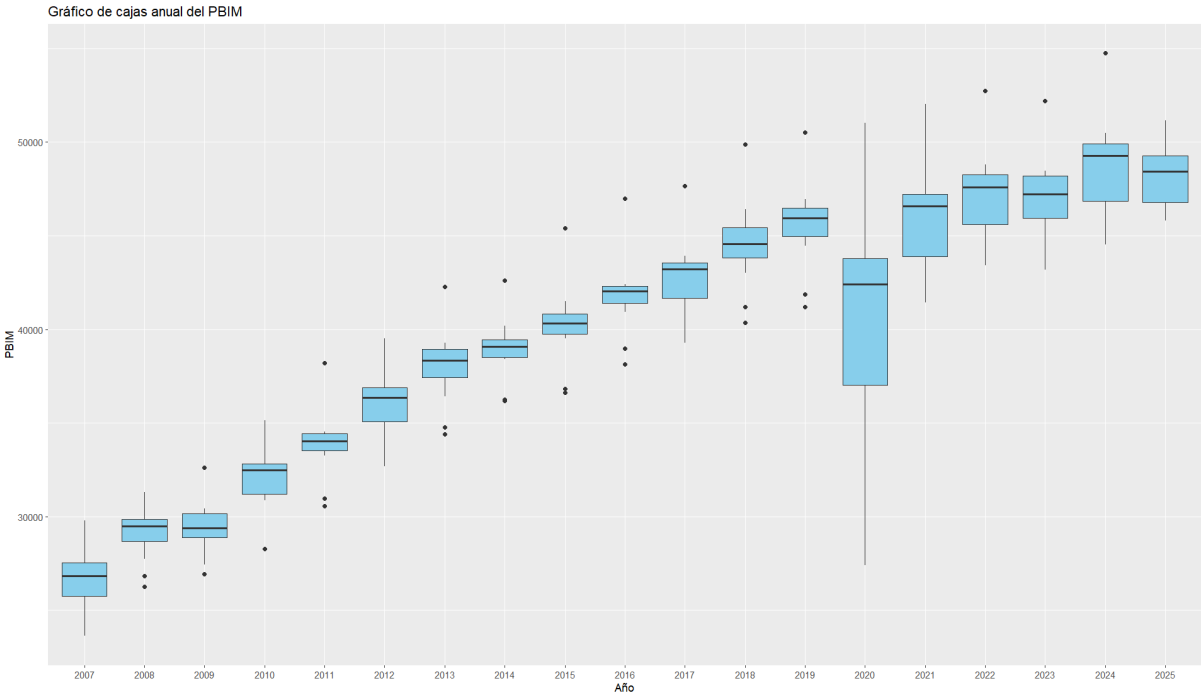

Figura 3: Gráfico de cajas anual del PBI mensual (2007–2025).

4. Descomposición de la serie temporal

Una de las herramientas más utilizadas en el análisis de series temporales es la descomposición mediante **STL (Seasonal-Trend decomposition using Loess)**.
Este método permite separar la serie en tres componentes principales:

- **Tendencia**: el movimiento a largo plazo de la serie.
- **Estacionalidad**: patrones que se repiten de manera periódica.
- **Resto o componente irregular**: variaciones aleatorias o no explicadas.

En un primer paso, se aplicó la función `stl()` de R, que implementa esta técnica de manera clásica.

Descomposición STL con base R

```
# Descomposición con STL (versión R)
pbi_stl <- stl(PBI, s.window = "periodic")
plot(pbi_stl, main = "Descomposición STL del PBI")
```

Si bien este procedimiento resulta efectivo, para efectos de una visualización más clara y moderna, se empleó la librería **feasts**, la cual permite trabajar con datos en formato `tsibble` y obtener gráficos más intuitivos.

Descomposición STL con `feasts`

```
# Descomposición STL con feasts
pbi_tsibble <- as_tsibble(PBI)

pbi_tsibble %>%
   model(STL(value ~ season(window = "periodic"))) %>%
   components() %>%
   autoplot() +
   labs(title = "Descomposición STL con feasts")
```

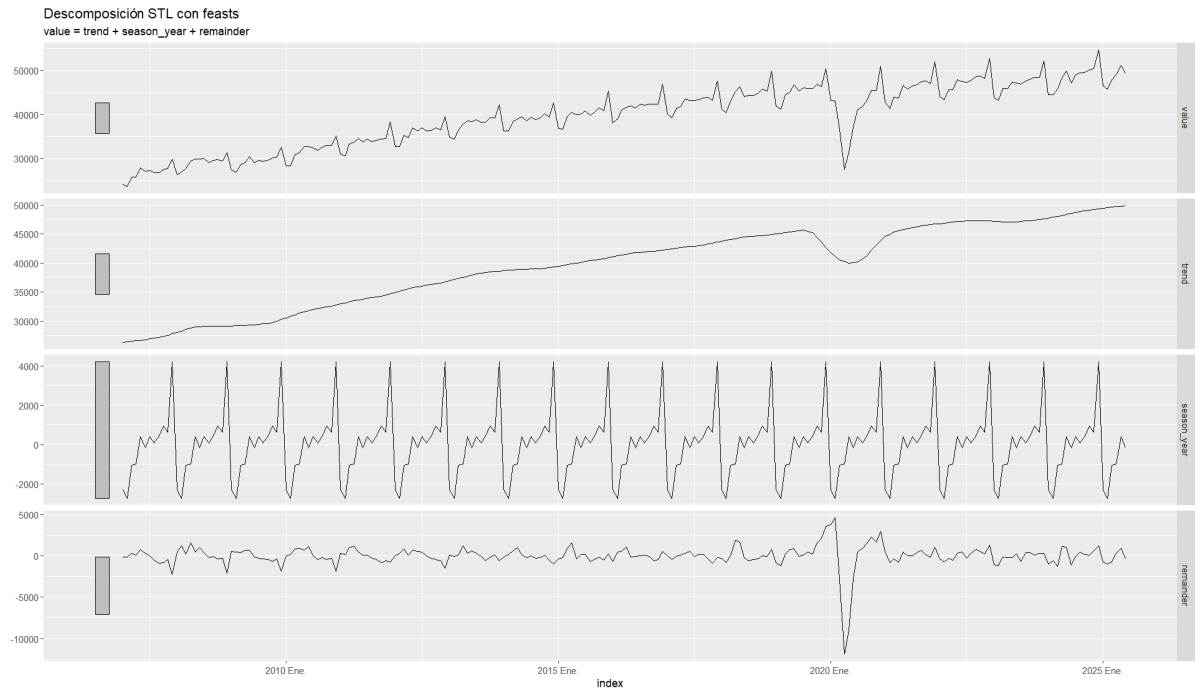

Figura 4: Descomposición STL del PBI mediante el paquete `feasts`.

A partir de esta descomposición, se observa que el **componente de tendencia** muestra un crecimiento sostenido del PBI desde 2007 hasta finales de 2019, seguido de una contracción abrupta en 2020 asociada a la pandemia de la COVID-19, tras la cual la serie retoma un patrón de recuperación, aunque a un nivel más moderado. La **estacionalidad** refleja un ciclo anual estable con picos y caídas que se repiten de manera consistente, lo que indica que los patrones productivos y de consumo mantienen regularidad a lo largo del tiempo. Finalmente, el **componente irregular** presenta fluctuaciones de baja magnitud en la mayor parte del periodo, salvo en 2020, donde se registra un choque atípico muy pronunciado que no puede explicarse ni por la tendencia ni por la estacionalidad. Esta evidencia confirma que, además de la dinámica estructural y estacional, existen eventos extraordinarios que influyen de manera significativa en la evolución del PBI peruano.

5. Autocorrelación simple y parcial

Con el fin de analizar la dependencia temporal de la serie, se calcularon la **función de autocorrelación simple (ACF)** y la **función de autocorrelación parcial (PACF)**. Estas herramientas permiten identificar patrones de correlación en diferentes rezagos y sirven como guía para la especificación de modelos ARIMA.

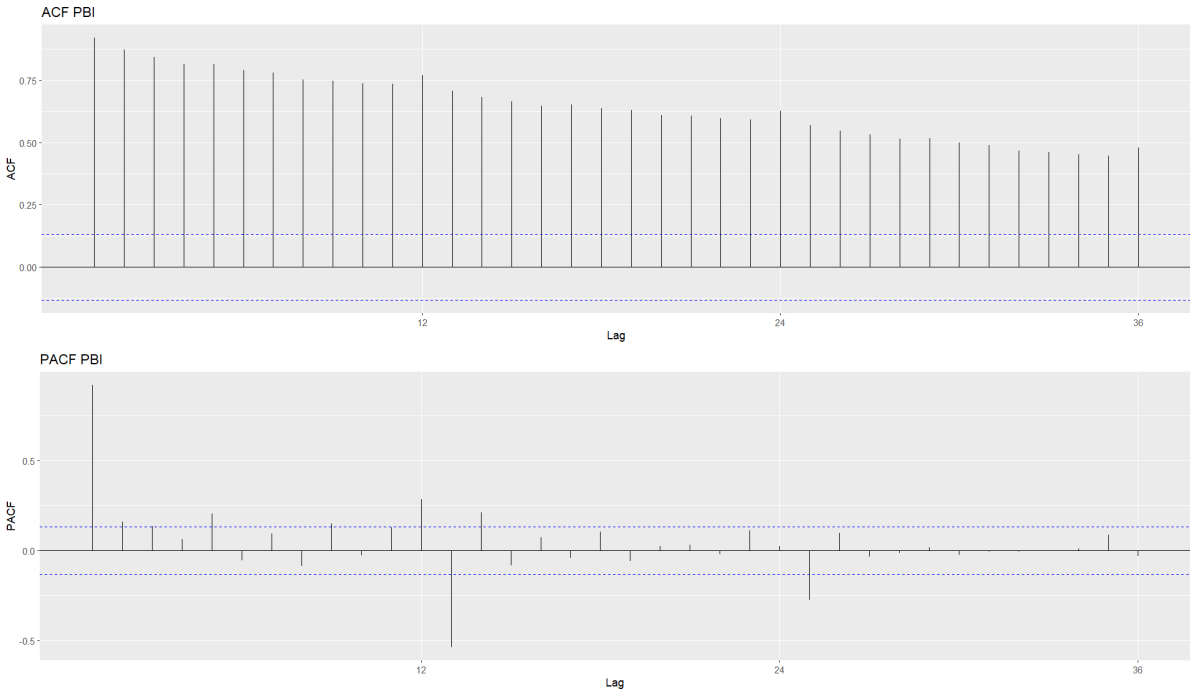

Figura 5: Autocorrelación simple (ACF) y parcial (PACF) del PBI.

La **ACF** muestra una alta autocorrelación positiva en los primeros rezagos que disminuye de forma lenta y persistente, lo cual refleja una fuerte dependencia temporal y es un indicio de no estacionariedad en la serie.
La **PACF**, en cambio, presenta un corte significativo en el primer rezago, mientras que los siguientes valores se mantienen dentro de los intervalos de confianza, lo que sugiere que el comportamiento del PBI puede explicarse principalmente a través de un proceso autorregresivo de primer orden (AR(1)).
En conjunto, estos resultados confirman la existencia de tendencia en la serie y la necesidad de aplicar una diferenciación para alcanzar la estacionariedad antes de proceder con el ajuste de un modelo ARIMA.

6. Estacionariedad gráfica

Para evaluar la estacionariedad de la serie del PBI, se analizaron la **serie original**, la **media móvil de 12 meses** y la **varianza móvil de 12 meses**. Estas herramientas permiten observar si la media y la varianza permanecen constantes a lo largo del tiempo, condición necesaria para considerar que una serie es estacionaria en sentido débil.

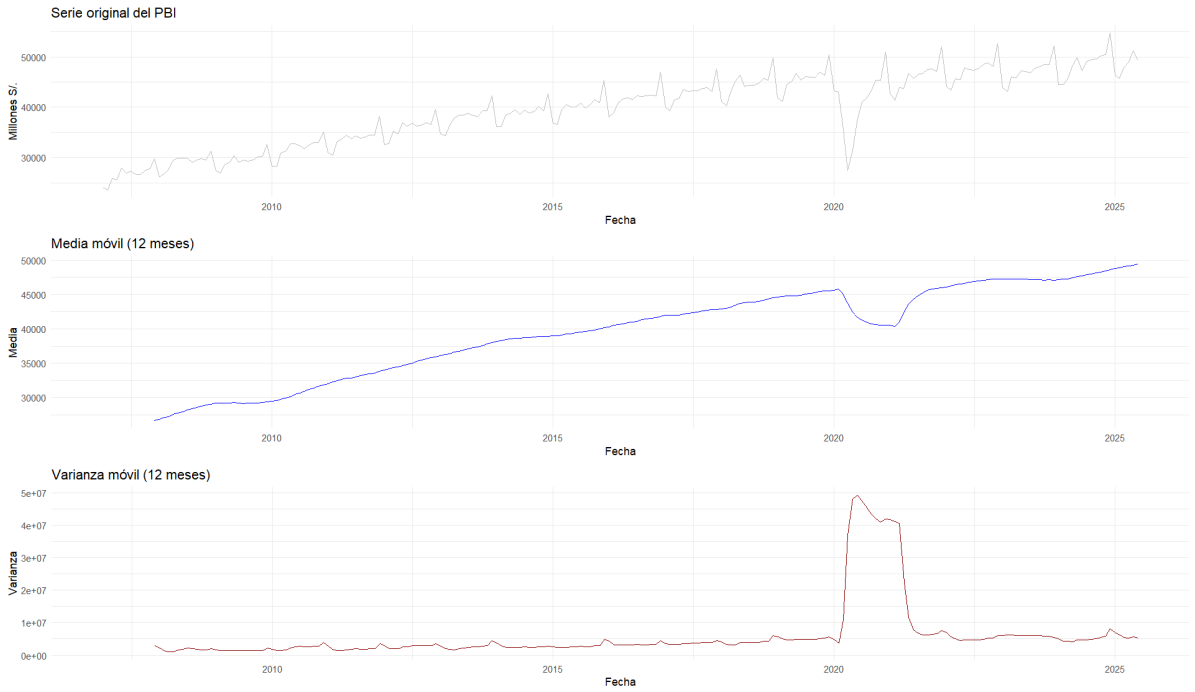

Figura 6: Serie original, media móvil y varianza móvil del PBI (2007–2025).

La **serie original** muestra un claro crecimiento a lo largo del tiempo, acompañado de fluctuaciones periódicas que reflejan estacionalidad.
En la **media móvil (12 meses)** se observa una tendencia creciente hasta el año 2019, una caída abrupta durante el 2020 y una posterior recuperación. Esto confirma la presencia de una tendencia no constante, lo cual constituye un indicio de no estacionariedad en la media.
En cuanto a la **varianza móvil (12 meses)**, se aprecia un incremento significativo durante el 2020, seguido de una estabilización en los años posteriores. Este comportamiento evidencia que la varianza tampoco se mantiene constante en todo el periodo, lo que refuerza la conclusión de no estacionariedad.
En conjunto, estos resultados sugieren que la serie del PBI no es estacionaria, dado que tanto la media como la varianza presentan cambios sustanciales a lo largo del tiempo.

7. Identificación de outliers

Como paso final del análisis exploratorio, se identificaron y corrigieron **valores atípicos (outliers)** en la serie del PBI. Estos valores extremos pueden distorsionar las medidas estadísticas y afectar la interpretación de la dinámica económica, por lo que resulta relevante detectarlos y tratarlos de manera adecuada.

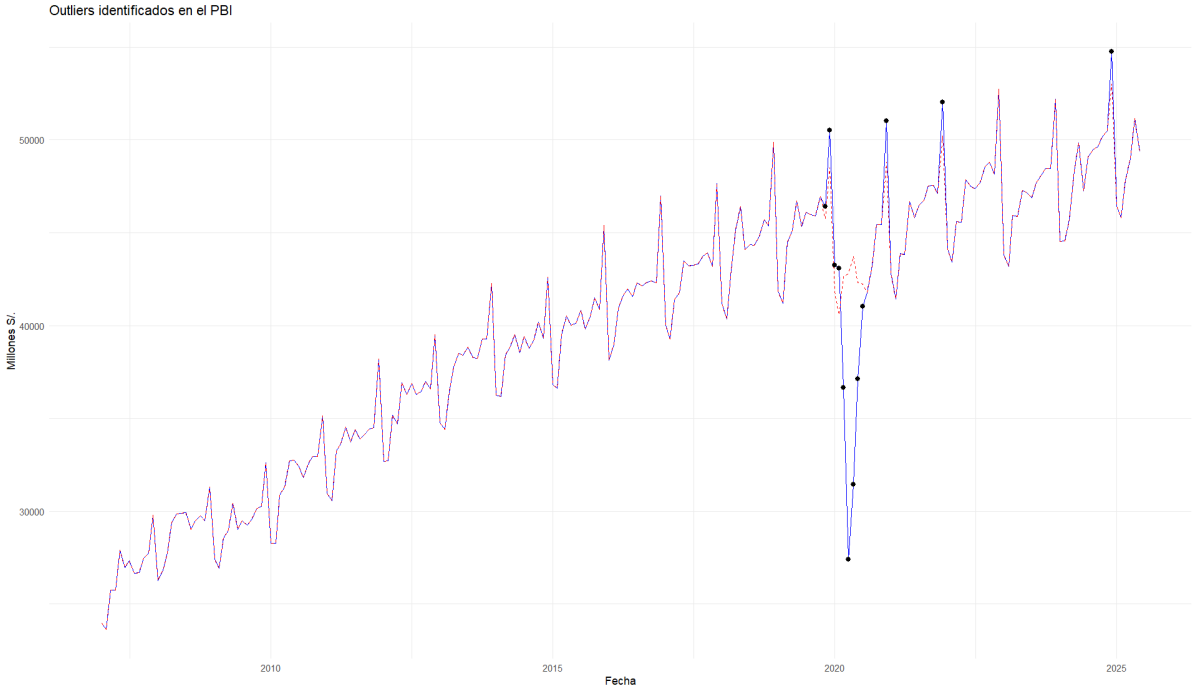

Figura 7: Outliers identificados en la serie del PBI.

En la gráfica anterior se resaltan en puntos negros los periodos en los que la serie presenta desviaciones atípicas respecto a su comportamiento esperado. La mayor concentración de outliers ocurre durante el 2020, lo cual coincide con la fuerte disrupción económica causada por la pandemia de COVID-19. Asimismo, se detectan valores extremos en finales de 2019, en diciembre de 2021 y en diciembre de 2024.
Para mitigar el efecto de estos eventos atípicos sobre el análisis, se aplicó un procedimiento de **limpieza de series temporales**, reemplazando los valores anómalos por estimaciones suavizadas basadas en la dinámica local de la serie.

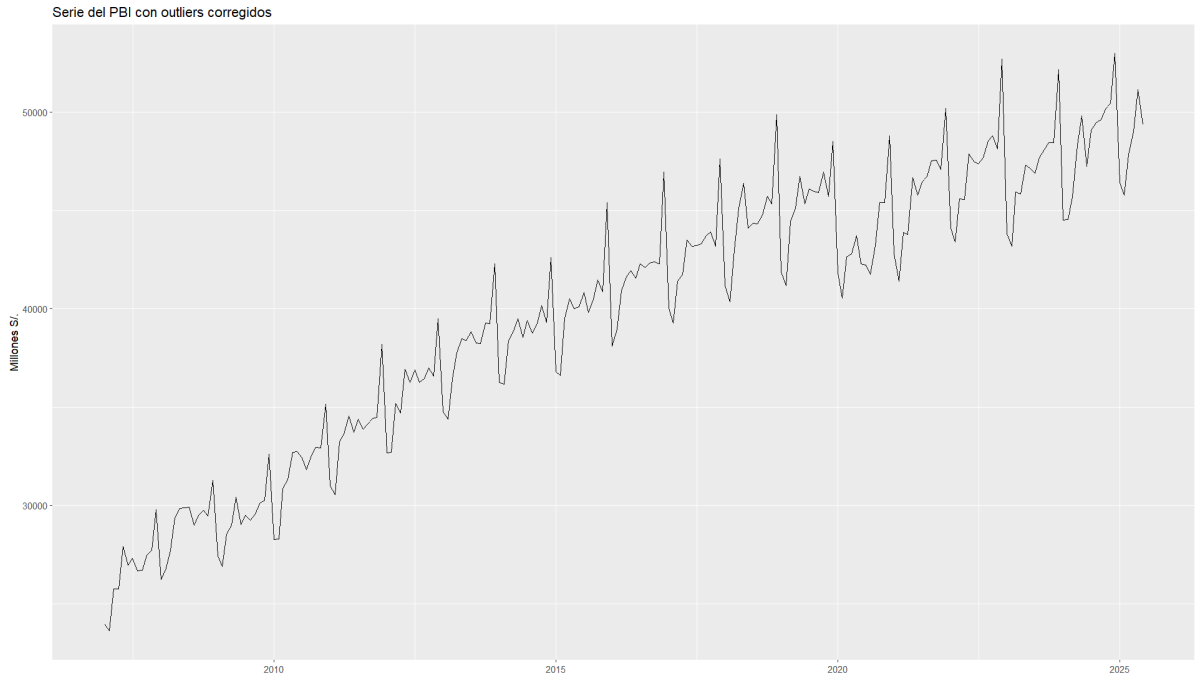

Figura 8: Serie del PBI con outliers corregidos.

La serie corregida mantiene las tendencias y patrones generales, pero sin los picos abruptos que podrían sesgar análisis posteriores. Este ajuste no busca eliminar información económica relevante, sino proporcionar una versión más estable de la serie que pueda ser utilizada en estudios posteriores de modelamiento y pronóstico.
Con este paso se concluye el análisis exploratorio, habiendo identificado tendencia, estacionalidad, cambios en la varianza y la presencia de valores atípicos. Estos hallazgos sientan las bases para investigaciones futuras que incorporen modelos predictivos más sofisticados.